ОТЧЁТ ПО ПРОЕКТУ: АНАЛИТИКА ВИДЕОПРОКАТА НА БАЗЕ PAGILA

Автор: Козлова Екатерина
Дата: 2026
Технологии: PostgreSQL 16, SQL, Power BI Desktop, DBeaver

---

1. Резюме проекта

Данный проект представляет собой комплексное аналитическое исследование данных компании видеопроката на основе датасета Pagila. Целью работы являлось извлечение бизнес-инсайтов из реляционной базы данных с использованием продвинутых SQL-запросов и визуализация ключевых метрик в интерактивном дашборде.

В рамках проекта были реализованы пять аналитических запросов, охватывающих анализ продуктовой линейки, сегментацию клиентской базы, оценку удержания клиентов и эффективности сотрудников. Результаты визуализированы в Microsoft Power BI Desktop, что обеспечивает возможность интерактивного изучения данных и принятия обоснованных управленческих решений.

2. Цели и задачи проекта

2.1. Цели в сфере бизнеса

1. Определить наиболее доходные фильмы и категории контента, чтобы оптимизировать стратегию закупок.
2. Сегментировать клиентов по уровню лояльности и значимости для более точного таргетинга маркетинговых кампаний.
3. Изучить динамику удержания клиентов и выявить основные причины их оттока.
4. Оценить производительность сотрудников и торговых точек.
5. Разработать инструмент для руководства, позволяющий отслеживать ключевые показатели эффективности.

2.2. Технические задачи

1. Внедрить и настроить базу данных PostgreSQL, используя датасет Pagila.
2. Создать оптимизированные SQL-запросы, применяя CTE, оконные функции и агрегации.
3. Разработать интерактивный дашборд в Power BI с функциями фильтрации и детализации.
4. Обеспечить возможность воспроизведения проекта через документацию и организацию репозитория.

3. Описание данных

3.1. Источник данных

Проект использует модифицированную версию классического датасета dvdrental, адаптированную под современный PostgreSQL и доступную в репозитории Pagila.

Характеристики датасета:

Параметр	Значение
Количество таблиц	15
Нормализация	Третья нормальная форма (3НФ)
Количество фильмов	1 000

Количество клиентов	599
Количество магазинов	2
Количество транзакций	~16 000
Период данных	2005-2006 гг.

3.3. Ключевые сущности

- **film**: Каталог фильмов с метаданными (название, рейтинг, длительность, цена проката).
- **category**: Жанровая классификация фильмов.
- **customer**: Информация о клиентах и их контактные данные.
- **rental**: Журнал аренд с указанием дат выдачи и возврата.
- **payment**: Финансовые транзакции с суммами платежей.
- **inventory**: Учёт физических копий фильмов в магазинах.
- **staff** и **store**: Данные о сотрудниках и торговых точках.

4.Техническая реализация

4.1. Архитектура решения

[Источники данных]

[PostgreSQL 16] <- [Схема Pagila: 15 таблиц, 3НФ]

[SQL-запросы] <- [CTE, оконные функции, агрегации]

[Power BI Desktop] <- [Дашборд с визуализациями]

[Экспорт: PDF, PNG, GitHub]

4.2. Подключение к базе данных

Подключение осуществлялось через коннектор PostgreSQL в Power BI Desktop с использованием следующих параметров:

- Сервер: localhost
- Порт: 5432
- База данных: pagila_analytics
- Аутентификация: PostgreSQL (пользователь postgres)

5.Аналитические запросы

5.1. Топ-10 фильмов по выручке

Технические особенности:

1. **Многотабличное соединение:** Запрос объединяет 6 таблиц (film, film_category, category, inventory, rental, payment) через INNER JOIN для получения полной информации о каждом фильме и его финансовых показателях.
2. **Оконные функции:**
   - SUM(SUM(p.amount)) OVER() — рассчитывает общую выручку по всем фильмам для вычисления процентной доли
   - RANK() OVER (ORDER BY SUM(p.amount) DESC) — присваивает рейтинг фильмам на основе выручки
3. **Агрегация данных:** Использование COUNT(DISTINCT ...) обеспечивает точный подсчет уникальных аренд и копий, избегая дублирования при соединении таблиц.
4. **Оптимизация:** Группировка по film_id вместо title повышает производительность и корректность обработки фильмов с одинаковыми названиями.

Ожидаемые результаты:

Запрос возвращает топ-10 фильмов с наибольшими финансовыми показателями. Типичные результаты показывают, что лидеры генерируют выручку в диапазоне $120-140, при этом каждый фильм составляет около 0.3% от общей выручки базы.

5.2. Анализ эффективности категорий

Технические особенности:

1. **CTE (Common Table Expression):** Подзапрос category_metrics выполняет предварительную агрегацию данных по категориям, что упрощает основной запрос и улучшает читаемость кода.
2. **LEFT JOIN:** Использование внешних соединений гарантирует, что все категории будут представлены в результатах, даже если в них отсутствуют фильмы или арендные транзакции.
3. **Обработка NULL:**
   - COALESCE(SUM(p.amount), 0) заменяет NULL на 0 для категорий без транзакций
   - NULLIF(film_count, 0) предотвращает деление на ноль при расчете выручки на фильм
4. **Оконные функции:**
   - SUM(total_revenue) OVER() вычисляет общую выручку для определения процентной доли
   - PERCENT_RANK() показывает относительную позицию категории в распределении (от 0.0 до 1.0)

Интерпретация результатов:

Категории с высоким percentile (близким к 1.0) и высокой выручкой на фильм представляют собой наиболее рентабельные направления для развития. Категории с низким показателем требуют пересмотра стратегии закупок или ценообразования.

5.3. Запрос 3: RFM-сегментация клиентов

Методология RFM-анализа:

RFM-анализ базируется на трех измерениях клиентского поведения:

1. **Recency (R) — Давность:** Количество дней с последней аренды. Чем меньше значение, тем выше вовлеченность клиента.
2. **Frequency (F) — Частота:** Общее количество аренд. Отражает лояльность и регулярность использования сервиса.
3. **Monetary (M) — Денежная ценность:** Общая сумма потраченных средств. Показывает финансовый вклад клиента в бизнес.

Алгоритм сегментации:

Шаг	Описание	SQL-реализация
1	Расчет базовых метрик для каждого клиента	CTE customer_rfm_base
2	Присвоение баллов (1-5) по каждому измерению	NTILE(5) в customer_rfm_scores
3	Классификация по сегментам на основе комбинации баллов	CASE в customer_segments

Технические особенности:

Технические особенности:

1. **Трехуровневая архитектура CTE:** Каждый уровень выполняет отдельную задачу (агрегация → скоринг → сегментация), что обеспечивает модульность и простоту поддержки кода.
2. **Функция NTILE(5):** Делит клиентов на 5 равных групп (квантилей) по каждому измерению. Для Recency сортировка по возрастанию (ASC), так как меньшее количество дней — лучший показатель. Для Frequency и Monetary — по убыванию (DESC).
3. **Составной рейтинг:** rfm_total_score (сумма R+F+M) варьируется от 3 до 15 и позволяет ранжировать клиентов по общей ценности.
4. **RFM-код:** Формат "R-F-M" (например, "5-4-5") обеспечивает детальную идентификацию профиля клиента.

Сегментация позволяет:
Оптимизировать маркетинговый бюджет через таргетирование
Повысить удержание клиентов через персонализированные коммуникации
Увеличить средний чек через апселлинг в сегментах с высоким потенциалом
Снизить отток через своевременную реактивацию

5.4. Когортный анализ удержания

Методология когортного анализа:
Определения:

- **Когорта:** Группа клиентов, совершивших первую аренду в один и тот же период (месяц).
- **Retention Rate (коэффициент удержания):** Процент клиентов когорты, оставшихся активными в последующие периоды.
- **Период анализа:** 6 месяцев с момента первой аренды.
- **Алгоритм расчета:**

Уровень CTE	Назначение	Ключевые операции
customer_cohorts	Определение когорты для каждого клиента	MIN(rental_date) + DATE_TRUNC('month')
rental_activity	Агрегация активности по месяцам	Расчет months_since_cohort через AGE()
cohort_sizes	Подсчет размера каждой когорты	COUNT(DISTINCT customer_id)
cohort_retention	Агрегация метрик удержания	GROUP BY cohort_month, months_since_cohort

- **Ключевые метрики:**

Метрика	Формула	Интерпретация
cohort_size	COUNT(DISTINCT customer_id)	Количество клиентов, пришедших в месяце когорты
active_customers	COUNT(DISTINCT customer_id) за период	Сколько клиентов совершили аренду в месяце N
retention_rate	(active_customers / cohort_size) × 100	Процент удержания относительно месяца 0
cohort_revenue	SUM(monthly_revenue)	Выручка от когорты в периоде
months_since_cohort	EXTRACT(MONTH FROM AGE(...))	Номер месяца с начала когорты (0, 1, 2...)

Технические особенности:

1. **DATE_TRUNC('month', date):** Усекает дату до начала месяца, обеспечивая группировку по месяцам. Например, '2005-03-15' → '2005-03-01'.
2. **AGE(date1, date2):** Вычисляет интервал между двумя датами. В сочетании с EXTRACT(MONTH FROM ...) позволяет определить, сколько месяцев прошло с момента первой аренды.
3. **Визуализация через REPEAT**
   Создает текстовую гистограмму из 20 символов, где заполненная часть пропорциональна retention rate.
4. **Фильтрация:** WHERE months_since_cohort <= 6 ограничивает анализ первыми шестью месяцами для релевантности данных.

Интерпретация результатов:

Типичная матрица удержания показывает:

- **Месяц 0:** 100% (все клиенты когорты)
- **Месяц 1:** 60-70% (естественный отток после первой аренды)
- **Месяц 2:** 40-50% (критическая точка)
- **Месяц 3+:** 30-40% (стабилизация лояльной базы)

5.5. Анализ эффективности сотрудников

Ключевые метрики:

Метрика	Описание	Формула	Бизнес-значение
total_rentals	Количество обработанных аренд	COUNT(DISTINCT rental_id)	Показатель нагрузки и продуктивности
unique_customers	Уникальные клиенты	COUNT(DISTINCT customer_id)	Охват клиентской базы
total_revenue	Совокупная выручка	SUM(payment_amount)	Прямой вклад в бизнес
avg_transaction	Средний чек	AVG(payment_amount)	Эффективность продаж
median_transaction	Медианный чек	PERCENTILE_CONT(0.5)	Устойчивая метрика без выбросов
revenue_share_pct	Доля в общей выручке	(Revenue_emp / Total_Revenue) × 100	Относительный вклад
revenue_rank	Позиция в рейтинге	RANK() OVER (...)	Сравнительная эффективность
revenue_per_customer	Выручка на клиента	Total_Revenue / Unique_Customers	Качество обслуживания
active_days	Рабочих дней	COUNT(DISTINCT DATE(rental_date))	Активность и доступность

Технические особенности:

1. **PERCENTILE_CONT(0.5) WITHIN GROUP (ORDER BY p.amount):**
   - Вычисляет медиану — значение, делящее выборку пополам
   - 50% транзакций ниже медианы, 50% выше
   - Преимущество перед средним: устойчивость к выбросам (очень крупным или мелким платежам)
   - Синтаксис WITHIN GROUP (ORDER BY ...) обязателен для упорядоченных агрегатных функций
2. **Оконные функции для сравнительного анализа:**
   - SUM(SUM(p.amount)) OVER() рассчитывает общую выручку по всем сотрудникам для определения процентной доли
   - RANK() OVER (ORDER BY SUM(p.amount) DESC) присваивает позицию в рейтинге, учитывая возможные ничьи
3. **Агрегация на уровне сотрудника:**
   - Группировка по staff_id с включением всех атрибутов сотрудника
   - Присоединение таблицы store для определения магазина
4. **Расчет рабочих дней**

Сравнительный анализ метрик:

Показатель	Средний чек (AVG)	Медианный чек (MEDIAN)
Чувствительность к выбросам	Высокая	Низкая
Репрезентативность	Средняя	Высокая
Использование	Общая оценка	Типичная транзакция

Пример интерпретации:
Если у сотрудника:

- avg_transaction = $5.50
- median_transaction = $2.99

Это указывает на наличие небольшого количества крупных транзакций, искажающих среднее значение. Медиана показывает, что типичный чек составляет $2.99.

Метрики эффективности:

1. **Выручка на клиента:**
   - Высокое значение (> $100) указывает на эффективный апселлинг и кросс-селлинг
   - Низкое значение (< $50) требует обучения техникам увеличения среднего чека
2. **Доля выручки:**
   - Сбалансированное распределение: каждый сотрудник 40-60% от идеальной доли (50% для 2 сотрудников)
   - Дисбаланс указывает на необходимость перераспределения нагрузки или обмена лучшими практиками
3. **Активные дни:**
   - Соотношение active_days / total_period показывает коэффициент занятости
   - Низкий показатель при высокой выручке на день указывает на высокую продуктивность в рабочие дни

Бизнес-применение:

1. **Система мотивации:** Привязка бонусов к total_revenue, revenue_per_customer и revenue_rank.
2. **Обучение и развитие:**
   - Сотрудники с низким avg_transaction → тренинги по апселлингу
   - Низкий unique_customers → развитие навыков работы с клиентской базой
3. **Оптимизация штатного расписания:** Анализ active_days и total_rentals для корректировки графика работы.
4. **Стандартизация процессов:** Изучение практик топ-сотрудников для масштабирования на всю команду.
5. **Сравнение магазинов:** Агрегация метрик по store_id выявляет различия в эффективности торговых точек.